

Rilevamento DPI in cantiere e compliance di sicurezza

Documento di analisi tecnica - Introduction to Computer Vision

Modelli: HOG + SVM e YOLOv8n - Dataset: SH17 - Output: SAFE / PARTIALLY SAFE / UNSAFE

Executive summary. Il progetto sviluppa una pipeline completa di Computer Vision per rilevare lavoratori e Dispositivi di Protezione Individuale (DPI) in immagini di cantiere. Il sistema combina una baseline classica HOG + SVM, un detector YOLOv8n fine-tuned su SH17 e un motore di compliance basato su regole. L'obiettivo non è sostituire il giudizio umano, ma fornire un supporto decisionale interpretabile.

Componente	Risultato principale
YOLOv8n	mAP@50 0.543, mAP@50-95 0.337, precision 0.628, recall 0.522
Baseline HOG + SVM	Accuracy 0.917, precision 0.913, recall 0.542, F1 0.680
Compliance	333 lavoratori: 309 UNSAFE, 14 PARTIALLY SAFE, 10 SAFE
Limite principale	Rilevamento dei DPI rari, soprattutto safety-vest

Figura 1. Esempio qualitativo della pipeline: rilevamento dei lavoratori, associazione dei DPI e classificazione finale della compliance.



Esempio di inferenza: bounding box dei DPI e stato SAFE sui lavoratori.

1. Definizione del problema

Il monitoraggio dell'utilizzo dei DPI nei cantieri è rilevante per la sicurezza, ma il controllo manuale può essere lento, discontinuo e soggetto a errore. Il progetto affronta questo problema costruendo una pipeline che rileva persone e DPI, associa i DPI ai lavoratori e produce un giudizio finale SAFE, PARTIALLY SAFE o UNSAFE.

Il sistema è pensato come supporto decisionale: le metriche ottenute, in particolare sulle classi rare, non giustificano un uso automatico o punitivo. Ogni output deve rimanere verificabile da un operatore umano.

2. Dataset SH17

Metrica	Valore
Immagini totali	8.099
Train	6.479
Validation	1.620
Oggetti annotati totali	75.994
Istanze di validation	15.358
Classi	17
Oggetti medi / immagine	9.38

SH17 include classi di DPI e parti del corpo. Le categorie più frequenti sono hands, person, head, face ed ear; i DPI più importanti per la compliance, come helmet e safety-vest, sono invece molto meno rappresentati.




Figura 2 - Distribuzione delle classi nel training set: le parti del corpo dominano il dataset, mentre helmet e safety-vest sono rare.

2.1 Criticità del dataset

Classe	Istanze train	Percentuale
hands	12.638	20.8%
person	11.068	18.3%
head	9.558	15.8%
helmet	773	1.3%
safety-vest	433	0.7%

Lo sbilanciamento è la proprietà più importante del dataset: il modello osserva molte più istanze di parti del corpo rispetto ai DPI centrali per la compliance. Questo impatta recall, mAP per classe e affidabilità finale del motore di compliance.

La seconda criticità è la dimensione degli oggetti. Molti DPI occupano una frazione ridotta dell'immagine; questo rende più frequenti i falsi negativi, soprattutto su caschi distanti, gilet parzialmente visibili, occhiali e protezioni auricolari.




Figura 3 - Distribuzione delle bounding box normalizzate: molti oggetti sono piccoli e quindi difficili da rilevare.

3. Metodologia

La pipeline segue un flusso completo: acquisizione dei dati, audit del dataset, preprocessing e augmentation, baseline classica, detector profondo, post-processing, compliance engine, valutazione e failure analysis.

La progettazione procede per complessità crescente: prima una baseline classica che classifica crop helmet/no_helmet, poi YOLOv8n per affrontare il problema reale di rilevamento multi-classe sull’immagine completa.

Fase	Ruolo nel progetto
Dataset audit	Comprendere distribuzione, sbilanciamento e dimensione degli oggetti
HOG + SVM	Baseline classica su crop binari helmet/no_helmet
YOLOv8n	Rilevamento multi-classe e localizzazione
Post-processing	NMS, soglie di confidenza e pulizia delle predizioni
Compliance engine	Associazione DPI-persona e classificazione SAFE/PARTIALLY SAFE/UNSAFE
Failure analysis	Individuazione delle modalità di errore e delle cause principali

4. Baseline classica: HOG + SVM

La baseline opera su crop già estratti e affronta un task binario: helmet vs no_helmet. I crop positivi derivano da box helmet (773), mentre i negativi derivano da box head senza sovrapposizione con caschi, limitati a 4.000. Il totale è 4.773 crop, con split stratificato 80/20 e 955 campioni in validazione.

Pipeline	Configurazione
Preprocessing	Crop -> resize 128x128 -> grayscale
Feature	HOG: 9 orientazioni, celle 8x8, blocchi 2x2
Classificatore	SVM RBF, C=10, class_weight=balanced




Figura 4 - Matrice di confusione HOG + SVM: alta precisione, ma recall limitata sui caschi.

4.1 Risultati e interpretazione della baseline

Metrica	Valore
Accuracy	0.917
Precision	0.913
Recall	0.542
F1-score	0.680

L'accuracy è elevata, ma la matrice evidenza un comportamento conservativo: il modello commette pochi falsi positivi (8), ma manca 71 caschi reali su 155. La baseline dimostra che le feature handcrafted sono utili su crop semplici, ma non risolvono localizzazione, rilevamento multi-classe e associazione DPI-persona.

5. Detector YOLOv8n

Il modello principale è YOLOv8n, fine-tuned su SH17. La variante nano è stata scelta per il compromesso tra accuratezza, costo computazionale e velocità di inferenza.

Parametro	Valore
Modello	YOLOv8n
Input size	640
Epochs	80
Batch size	16
Parametri	3.0 M
GFLOPs	8.1
Hardware	Apple M4 Max
Backend	PyTorch MPS
Tempo training	circa 18.6 ore
Early stopping	patience 20, non attivata

YOLOv8 fornisce bounding box e classe in un unico forward pass, integra il post-processing e consente una velocità compatibile con scenari real-time.




Figura 5 - Curve di training: le loss decrescono e mAP@50/mAP@50-95 migliorano in modo stabile fino alle ultime epoche.

6. Risultati YOLO

La valutazione è stata eseguita sullo split ufficiale di validazione: 1.620 immagini, 15.358 istanze e 17 classi.

Metrica	Valore
Precision	0.628
Recall	0.522
mAP@50	0.543
mAP@50-95	0.337
Tempo di inferenza	~2.4 ms/img

Il confronto con il benchmark ufficiale SH17 per YOLOv8n mostra uno scarto contenuto: 0.543 vs 0.580 in mAP@50 e 0.337 vs 0.366 in mAP@50-95. Considerando che è stato eseguito un singolo esperimento completo in locale, il risultato è coerente con l'obiettivo del progetto.

Modello	Precision	Recall	mAP@50	mAP@50-95
Nostro YOLOv8n	0.628	0.522	0.543	0.337
YOLOv8n ufficiale SH17	0.675	0.536	0.580	0.366




Figura 6 - Curva Precision-Recall: le classi frequenti mantengono curve più robuste; le classi rare degradano rapidamente.

6.1 Prestazioni per classe

Classi forti	mAP@50	Classi deboli	mAP@50
head	0.894	safety-vest	0.431
face	0.891	face-guard	0.378
person	0.887	safety-suit	0.288
hands	0.826	tool	0.279
ear	0.726	ear-mufs	0.194
helmet	0.661	foot	0.102

Le classi più forti sono generalmente frequenti e visivamente più grandi. Le classi deboli sono rare, piccole o molto variabili. Il casco raggiunge una prestazione adeguata per il prototipo; il gilet resta invece il collo di bottiglia principale.

6.2 Interpretazione della matrice di confusione

La matrice di confusione normalizzata mostra che molte classi rare vengono confuse con il background. Questo conferma che la bassa performance non dipende solo dall'architettura, ma anche dalla distribuzione del dataset e dalla scala degli oggetti.




Figura 7 - Matrice di confusione normalizzata: background e classi rare spiegano una parte rilevante degli errori.

7. Motore di compliance

Il motore di compliance associa i DPI rilevati ai box person tramite regole geometriche basate su centro della bounding box, posizione relativa e overlap. La regola finale è semplice e interpretabile: casco + gilet = SAFE; uno solo = PARTIALLY SAFE; nessuno = UNSAFE.

DPI rilevati sul lavoratore	Stato
Casco + gilet	SAFE
Solo casco o solo gilet	PARTIALLY SAFE
Nessuno dei due	UNSAFE

La valutazione su 200 immagini e 333 lavoratori rilevati produce 309 UNSAFE, 14 PARTIALLY SAFE e 10 SAFE. Questo risultato non va letto come reale distribuzione delle violazioni: l'elevato numero di UNSAFE deriva in larga parte dalla mancata rilevazione dei DPI, soprattutto dei gilet.

Stato	Conteggio	Percentuale
UNSAFE	309	92.8%
PARTIALLY SAFE	14	4.2%
SAFE	10	3.0%

8. Failure analysis

Tipo	Conteggio	Interpretazione
person_overcount	11	più box person predetti rispetto al ground truth
person_undercount	7	lavoratori presenti ma non rilevati
helmet_missed	2	casco annotato ma non rilevato

L'errore dominante per la compliance è il falso UNSAFE causato da rilevamenti mancati di safety-vest. Il problema è coerente con la bassa frequenza della classe nel dataset (0.7%) e con la sua mAP@50 pari a 0.431.

9. Considerazioni etiche

Un sistema di questo tipo può supportare la sicurezza, ma introduce rischi legati a falsi allarmi, privacy e uso improprio. Le immagini di cantiere possono contenere persone identificabili; un utilizzo reale richiederebbe minimizzazione dei dati, anonimizzazione quando possibile, regole di conservazione e accessi controllati.

Il 92.8% di UNSAFE osservato nella valutazione non rappresenta necessariamente vere violazioni. Usare il sistema come strumento automatico di controllo produrrebbe decisioni non affidabili. La responsabilità finale deve rimanere umana.

10. Limiti del progetto

- Un solo dataset: la valutazione è limitata a SH17 e non misura la generalizzazione su altri cantieri.
- Un solo training completo: non sono state condotte ablation sistematiche su augmentation, soglie o modelli alternativi.
- Nessun confronto con YOLOv8s: previsto come lavoro futuro a causa del costo computazionale.
- Compliance rule-based: interpretabile ma fragile in presenza di occlusioni o persone sovrapposte.

11. Sviluppi futuri

- Oversampling, class weighting e copy-paste augmentation per DPI rari.
- Inferenza a risoluzione più alta o a tile per oggetti piccoli.
- Soglie di confidenza specifiche per classe, soprattutto helmet e safety-vest.
- Tracking multi-frame e pose estimation per stabilizzare conteggi e associazione DPI-persona.
- Validazione su immagini o video provenienti da altri contesti.

12. Conclusioni

Il progetto dimostra la fattibilità di una pipeline completa per rilevare DPI e stimare la compliance in immagini di cantiere. YOLOv8n raggiunge mAP@50 0.543 e mAP@50-95 0.337, con inferenza di circa 2.4 ms/img, avvicinandosi al benchmark ufficiale SH17.

La baseline HOG + SVM è utile come riferimento metodologico ma non risolve il problema completo, perché non localizza oggetti e non gestisce scene multi-classe. La failure analysis mostra che il limite principale non è il rilevamento delle persone, ma il riconoscimento dei DPI rari, soprattutto safety-vest. Per un utilizzo operativo servirebbero dati più bilanciati, validazione esterna e mantenimento dell'operatore umano nel processo decisionale.

Riferimenti. SH17 Dataset - <https://github.com/ahmadmughees/SH17dataset>; Ultralytics YOLO - <https://docs.ultralytics.com>; Dalal & Triggs, Histograms of Oriented Gradients for Human Detection, CVPR 2005.